PERANCANGAN DAN IMPLEMENTASI MULTI-AGENT SECURITY GATE DENGAN EVIDENCE-BASED ARBITER UNTUK VERIFIKASI KEAMANAN KODE HASIL LARGE LANGUAGE MODEL

LAPORAN TUGAS AKHIR

Disusun sebagai syarat kelulusan tingkat sarjana

Oleh

MUHAMMAD ADHA RIDWAN

NIM : 13523098



PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
<Bulan Tahun>

PERANCANGAN DAN IMPLEMENTASI MULTI-AGENT SECURITY GATE DENGAN EVIDENCE-BASED ARBITER UNTUK VERIFIKASI KEAMANAN KODE HASIL LARGE LANGUAGE MODEL

LAPORAN TUGAS AKHIR

Oleh

MUHAMMAD ADHA RIDWAN
NIM : 13523098

Program Studi Sarjana Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Laporan Tugas Akhir
di Bandung, pada tanggal <Tanggal Pengesahan>

Pembimbing I,	Pembimbing II,
Ir. Yudistira Dwi Wardhana Asnar, S.T., Ph.D.	Galuh Barata, S.T., M.T.
NIP. 198008272015041002	NIP. <NIP Pembimbing II>

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Pelanggaran Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung.

Bandung, <Tanggal Pengesahan>

Muhammad Adha Ridwan

NIM : 13523098

ABSTRAK

PERANCANGAN DAN IMPLEMENTASI MULTI-AGENT SECURITY GATE DENGAN EVIDENCE-BASED ARBITER UNTUK VERIFIKASI KEAMANAN KODE HASIL LARGE LANGUAGE MODEL

Oleh

MUHAMMAD ADHA RIDWAN

NIM : 13523098

Tuliskan ringkasan abstrak bahasa Indonesia di sini. Abstrak memuat permasalahan yang dikaji, metode/teknik keinformatikaan yang digunakan untuk menyelesaikan masalah, hasil yang dicapai, dan kesimpulan. Panjang abstrak maksimal 300 kata dan ditulis dalam satu spasi.

Kata Kunci: Kata Kunci 1, Kata Kunci 2, Kata Kunci 3

ABSTRACT

DESIGN AND IMPLEMENTATION OF A MULTI-AGENT SECURITY GATE WITH AN EVIDENCE-BASED ARBITER FOR SECURITY VERIFICATION OF CODE GENERATED BY LARGE LANGUAGE MODELS

By

MUHAMMAD ADHA RIDWAN

NIM : 13523098

Write the English abstract here. It summarizes the research problem, methodology, key findings, and conclusions. Maximum 300 words, single-spaced.

Keywords: Keyword 1, Keyword 2, Keyword 3

KATA PENGANTAR

Puji dan syukur dipanjatkan ke hadirat Tuhan Yang Maha Esa atas berkat dan rahmat-Nya sehingga Laporan Tugas Akhir ini dapat diselesaikan. Penulis mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Dosen Pembimbing yang telah memberikan bimbingan, arahan, dan masukan berharga.
2. Para dosen dan staf pengajar Program Studi Sarjana Teknik Informatika STEI ITB.
3. Rekan-rekan mahasiswa dan seluruh pihak yang telah mendukung pelaksanaan tugas akhir ini.

DAFTAR ISI

BAB I Pendahuluan 1

I.1 Latar Belakang 1

I.2 Rumusan Masalah 3

I.3 Tujuan Tugas Akhir 4

I.4 Batasan Masalah 4

I.5 Metodologi 5

I.6 Sistematika Pembahasan 7

BAB II Studi Literatur 8

II.1 Keamanan Kode Hasil LLM 8

II.1.1 Kebenaran dan keamanan kode 8

II.1.2 Pengaruh prompt dan cara pengujian 9

II.1.3 Dataset penelitian 10

II.2 Pemeriksaan Kerentanan dengan SAST dan LLM 11

II.2.1 Pemeriksaan kode secara statis 11

II.2.2 Penggunaan LLM untuk memeriksa hasil SAST . . 12

II.2.3 Peran SAST dalam pengambilan keputusan 13

II.3 Sistem Multi-Agen untuk Keamanan Kode 14

II.3.1 Pembagian tugas antaragen 14

II.3.2 Pembuatan, pemeriksaan, dan pengujian kode 14

II.3.3 Penggabungan hasil pemeriksaan 15

II.3.4 Evidence-Based Arbiter 16

II.3.5 Biaya penggunaan model 18

II.4 Perbaikan Kode Otomatis 18

II.4.1 Perbaikan berdasarkan hasil pemeriksaan 18

II.4.2 Pemisahan agen perbaikan 19

II.4.3 Pemeriksaan ulang dan batas perbaikan 20

II.5 Ketahanan Gate terhadap Serangan 21
II.5.1 Serangan pada agen pemeriksa 21
II.5.2 Hasil penelitian serangan pada reviewer 22
II.5.3 Sanitizer dan aturan keputusan 22
BAB III Analisis dan Perancangan Solusi 24
III.1 Analisis Masalah 24
III.2 Kebutuhan Sistem 24
III.3 Perancangan Arsitektur 24
BAB IV Implementasi dan Evaluasi 25
IV.1 Lingkungan Implementasi 25
IV.2 Prosedur dan Skenario Pengujian 25
IV.3 Hasil Pengujian dan Diskusi 25
BAB V Kesimpulan dan Saran 26
V.1 Kesimpulan 26
V.2 Saran 26
DAFTAR PUSTAKA 27
LAMPIRAN A Pernyataan Penggunaan Kecerdasan Buatan (AI) 32
LAMPIRAN B Contoh Lampiran Teknis 33
B.1 Spesifikasi Lingkungan Pengujian 33

DAFTAR GAMBAR

DAFTAR TABEL

Tabel 1 Daftar Singkatan yang Digunakan dalam Laporan x

Tabel 2 Rincian Penggunaan Alat AI dalam Penyusunan Tugas Akhir 32

DAFTAR SINGKATAN DAN ISTILAH

Tabel 1: Daftar Singkatan yang Digunakan dalam Laporan

Singkatan	Keterangan
AI	Artificial Intelligence (Kecerdasan Buatan)
API	Application Programming Interface
ITB	Institut Teknologi Bandung
STEI	Sekolah Teknik Elektro dan Informatika
TA	Tugas Akhir

BAB I
PENDAHULUAN

Bab ini menjelaskan dasar pengerjaan Tugas Akhir. Pembahasan mencakup latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika pembahasan.

I.1 Latar Belakang

Large language model (LLM) dapat membantu pengembang membuat kode dari instruksi bahasa alami. Namun, kode yang menghasilkan keluaran sesuai permintaan belum tentu memenuhi kebutuhan keamanan. Sebagai contoh, fungsi untuk mengambil data dapat berjalan dengan benar, tetapi tetap membuka peluang injeksi SQL apabila masukan pengguna tidak ditangani dengan tepat. CyberSecEval melaporkan bahwa model yang diuji menghasilkan saran kode rentan pada rata-rata sekitar 30% kasus dalam benchmark tersebut (Bhatt et al., 2023). Hasil ini menunjukkan perlunya pemeriksaan keamanan sebelum kode hasil LLM digunakan. Persentase tersebut merupakan hasil pada benchmark dan model yang diuji, sehingga tidak berlaku untuk seluruh kode hasil LLM.

Salah satu cara memeriksa kode adalah *static application security testing* (SAST), yaitu pemeriksaan tanpa menjalankan program. SAST dapat menemukan pola kelemahan melalui aturan yang telah ditentukan. Akan tetapi, peringatannya masih dapat berupa *false positive*, yaitu temuan yang sebenarnya tidak menunjukkan kerentanan. LLM dapat membantu menilai peringatan dengan membaca konteks kode. QASecClaw menggunakan pendekatan ini dan melaporkan penurunan false positive yang disertai penurunan recall (Ameen et al., 2026). Hal tersebut menunjukkan bahwa penyaringan peringatan juga dapat menghilangkan sebagian temuan yang benar.

Pendekatan lain membagi pekerjaan kepada beberapa agen. AutoSafeCoder menghubungkan agen pembuat kode, reviewer, dan fuzzing dalam proses perbaikan

berulang (Nunez et al., 2024). Multi-LLMSecCodeEval juga membandingkan kerja sama beberapa model dan alat analisis statis pada tahap generasi, deteksi, serta perbaikan kode (Sabir et al., 2026). Kedua penelitian tersebut menjadi dasar pengembangan alur pemeriksaan kode hasil LLM. Penggunaan beberapa agen dan perbaikan berulang sudah diteliti, sehingga kontribusi penelitian perlu dijelaskan melalui cara komponen bekerja dan hasil evaluasinya.

Dalam alur pemeriksaan tersebut, hasil antaragen dan alat dapat berbeda. Reviewer dapat menilai suatu peringatan tidak relevan, sedangkan alat masih melaporkan kelemahan. Pengujian juga dapat gagal dijalankan karena lingkungan yang tidak sesuai. Keadaan tersebut memerlukan aturan tindak lanjut yang jelas. Refute-or-Promote menunjukkan pentingnya pemeriksaan empiris: salah satu kandidat kelemahan yang didukung beberapa reviewer dibantah melalui pengujian (Agarwal, 2026). Dengan demikian, alasan yang diberikan agen perlu diperiksa bersama bukti yang tersedia sebelum menjadi dasar keputusan.

Penelitian Beyond QASecClaw turut menguji hubungan penilaian model dengan bukti alat. Pada pengaturan Java yang diuji, penambahan konteks agen tidak memberikan manfaat yang konsisten dibandingkan pemeriksaan deterministik. Studi tersebut juga menyoroti kesesuaian bukti dengan program dan kondisi yang diperiksa (Al Mamun et al., 2026). Temuan ini memperkuat kebutuhan untuk mencatat asal bukti dan menguji manfaat tambahan agen. Hasilnya tetap dibatasi oleh konstruksi eksperimen dan model yang digunakan dalam penelitian tersebut.

Selain perbedaan hasil, reviewer dapat menerima teks yang sengaja diarahkan untuk memengaruhi penilaiannya. Komentar pada kode, misalnya, dapat berisi pernyataan bahwa kode telah diaudit dan boleh diterima. Sanitizer dapat menyiapkan masukan untuk mengurangi teks semacam ini. Namun, manfaatnya perlu diuji. Thornton menemukan bahwa pengaruh komentar adversarial tidak signifikan pada pengujian berpasangan, sedangkan penghapusan komentar dapat menurunkan kemampuan deteksi model yang lebih lemah (Thornton, 2026). Oleh karena itu, evaluasi pertahanan perlu tetap memperhatikan kemampuan menemukan kelemahan pada kode tanpa serangan.

Berdasarkan permasalahan tersebut, Tugas Akhir ini mengusulkan perancangan dan implementasi *multi-agent security gate* dengan *Evidence-Based Arbiter*. Gate ditempatkan setelah generator untuk memeriksa kode sebelum diteruskan. Agen bertugas menganalisis temuan, melakukan triase, menyusun pengujian, dan memeriksa kelengkapan bukti. Arbiter non-LLM menerapkan kebijakan untuk menentukan apakah kode diterima (*pass*), diperbaiki (*revise*), atau ditahan untuk ditinjau manusia (*block*). Kode yang diperbaiki oleh Fixer kembali menjalani pemeriksaan. Setiap keputusan dihubungkan dengan versi kode, hasil alat, hasil pengujian, dan aturan yang digunakan.

Fokus penelitian adalah ketepatan keputusan penerimaan kode ketika bukti tidak lengkap atau bertentangan, termasuk setelah perbaikan dan ketika reviewer menerima komentar manipulatif. Pengujian akan membandingkan gate dengan pemeriksaan yang lebih sederhana, serta mengukur dampak sanitizer dan aturan arbiter. Jumlah kode rentan yang lolos perlu dinilai bersama penerimaan kode tidak rentan, kasus yang ditahan, keberhasilan patch, dan biaya penggunaan model. Dalam Tugas Akhir ini, verifikasi keamanan berarti pemeriksaan terhadap persyaratan dan kategori kelemahan yang ditetapkan. Label lolos gate menunjukkan bahwa pemeriksaan tersebut terpenuhi, dengan cakupan sesuai pengujian yang dilakukan.

I.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah Tugas Akhir ini adalah sebagai berikut.

1. Bagaimana merancang dan mengimplementasikan multi-agent security gate dengan Evidence-Based Arbiter yang menggunakan bukti pemeriksaan untuk menentukan keputusan pass, revise, atau block, termasuk ketika bukti tidak lengkap atau bertentangan?
2. Bagaimana ketepatan keputusan gate dan hasil perbaikan kode dibandingkan dengan SAST saja serta SAST dengan satu reviewer LLM, ditinjau dari kode

rentan yang lolos, penerimaan kode tidak rentan, fungsi kode, dan biaya pemeriksaan?

3. Bagaimana pengaruh sanitizer dan aturan arbiter terhadap ketahanan keputusan gate ketika reviewer menerima komentar manipulatif, serta terhadap kemampuan pemeriksaan pada kode tanpa serangan?

I.3 Tujuan Tugas Akhir

Tugas Akhir ini bertujuan mengembangkan dan mengevaluasi sistem pemeriksaan keamanan kode hasil LLM. Tujuan yang sesuai dengan rumusan masalah adalah sebagai berikut.

1. Menghasilkan implementasi gate yang menghubungkan agen pemeriksa, alat analisis statis, pengujian, dan perbaikan kode dengan arbiter non-LLM. Implementasi menyediakan aturan tindak lanjut untuk bukti yang belum lengkap atau bertentangan, serta mencatat dasar setiap keputusan.
2. Mengukur ketepatan keputusan dan hasil perbaikan gate dibandingkan dengan pembanding yang ditetapkan. Pengukuran mencakup tingkat kode rentan yang lolos, tingkat penerimaan kode tidak rentan, hasil deteksi, keberhasilan patch yang tetap memenuhi uji fungsi, jumlah kasus yang ditahan, penggunaan token, dan waktu pemrosesan.
3. Menilai perubahan keputusan pada pasangan kode tanpa serangan dan kode dengan komentar manipulatif. Evaluasi membandingkan penggunaan sanitizer dan aturan arbiter dengan kondisi ketika masing-masing komponen tersebut dihilangkan atau diganti oleh keputusan reviewer.

I.4 Batasan Masalah

Ruang lingkup Tugas Akhir ini dibatasi sebagai berikut.

1. Objek pengujian berupa fungsi atau potongan kode Python hasil LLM. Pengujian menggunakan tugas yang diambil dari SecurityEval dan subset Python LLMSecEval (Siddiq & Santos, 2022; Tony et al., 2023). Rancangan awal difokuskan pada CWE-22, CWE-78, CWE-89, CWE-502, dan CWE-798. Pemilihan sampel mempertimbangkan kelengkapan label acuan, aturan

pemeriksaan, dan dukungan pengujian; sampel yang dikeluarkan dicatat beserta alasannya.

2. Sistem menggunakan model LLM yang telah tersedia, tanpa melatih atau melakukan fine-tuning model. Identitas model, versi prompt, parameter pemanggilan, serta versi dan aturan alat dicatat pada konfigurasi eksperimen.
3. Analisis statis menggunakan Semgrep dan Bandit. Pengujian fungsi serta keamanan dilakukan dalam lingkungan terisolasi untuk sampel yang memenuhi kebutuhan lingkungan. Pemeriksaan yang tidak berjalan dicatat sebagai tidak teruji dan menghalangi pass jika termasuk pemeriksaan wajib.
4. Kebijakan arbiter mencakup penerimaan, permintaan perbaikan, dan penahanan kode. Keputusan block merupakan permintaan tinjauan manusia; proses peninjauan oleh pengguna di lingkungan produksi berada di luar pengujian ini. Batas awal remediasi adalah dua ronde perbaikan setelah keluaran pertama.
5. Skenario manipulasi reviewer dibatasi pada perubahan atau penyisipan komentar yang mempertahankan perintah dan perilaku program. Penyerang tidak mengubah aturan arbiter, prompt sistem, hasil alat, atau knowledge store. Sanitizer menghasilkan tampilan khusus reviewer dan mempertahankan kode asli untuk pemindaian serta eksekusi.
6. Apabila contoh pola dan patch digunakan dalam knowledge store, isinya berasal dari data pengembangan dan dibekukan sebelum pengujian akhir. Patch serta label sampel uji tidak digunakan sebagai contoh retrieval untuk sampel yang sama.
7. Evaluasi dilakukan pada lingkungan eksperimen yang terkontrol. Hasilnya dibatasi oleh tugas, CWE, model, alat, dan bentuk serangan yang diuji. Pemeriksaan aplikasi utuh, penerapan produksi, serta serangan melalui dependensi berada di luar ruang lingkup.

I.5 Metodologi

Pengerjaan Tugas Akhir dilakukan melalui pengembangan sistem dan eksperimen terkontrol. Tahap perancangan serta implementasi dapat diulang

berdasarkan hasil pengujian pada data pengembangan. Sebelum evaluasi akhir, konfigurasi dan kebijakan dibekukan agar hasil pembandingan menggunakan kondisi yang jelas. Tahap pengerjaan meliputi hal berikut.

1. **Studi literatur dan analisis kebutuhan.** Tahap ini menelaah keamanan kode hasil LLM, analisis statis, kerja sama agen, perbaikan kode, dan manipulasi reviewer. Hasil telaah digunakan untuk menentukan kebutuhan gate, bukti yang harus tersedia, kondisi kegagalan, serta pembanding yang sesuai.
2. **Penyiapan data dan skenario evaluasi.** Tahap ini membekukan versi dataset, memeriksa identitas dan duplikasi sampel, serta memisahkan data pengembangan dari data uji. Label acuan diperiksa terpisah dari keputusan alat di dalam gate. Sampel rentan dan tidak rentan disiapkan, bersama pasangan kode dengan dan tanpa komentar manipulatif. Skenario juga mencakup bukti yang bertentangan, respons agen tidak valid, dan pengujian yang tidak berjalan.
3. **Perancangan dan implementasi sistem.** Tahap ini menyusun aliran pemeriksaan, format bukti, kebijakan arbiter, dan hubungan antaragen. Implementasi mencakup sanitizer, pemanggilan SAST, penyiapan serta eksekusi pengujian, penyimpanan hasil, dan alur perbaikan. Setiap patch diperiksa ulang dengan bukti yang terkait pada versi kode terbaru.
4. **Pengujian dan pembandingan.** Tahap ini membandingkan generator tanpa gate, SAST saja, SAST dengan satu reviewer, dan gate lengkap pada tugas yang sama. Pengaruh komponen diuji dengan menonaktifkan sanitizer serta mengganti keputusan arbiter dengan keputusan reviewer, sementara bukti pemeriksaan lainnya dipertahankan. Generator dipertahankan sama, sedangkan batas revisi disamakan pada kondisi yang mencakup perbaikan. Perbedaan anggaran dicatat.
5. **Analisis hasil dan penyusunan kesimpulan.** Tahap ini menganalisis tingkat kode rentan yang memperoleh pass, penerimaan kode tidak rentan, precision, recall, F1, cakupan pemeriksaan, keberhasilan patch, dan regresi fungsi atau keamanan. Keberhasilan serangan diukur dari perubahan menjadi pass pada kode

rentan yang semula ditahan. Seluruh kegagalan, token, waktu pemrosesan, serta ketidakpastian hasil turut dilaporkan agar penurunan kode rentan yang lolos dapat dinilai bersama biaya dan jumlah kasus yang ditahan.

I.6 Sistematika Pembahasan

Laporan Tugas Akhir disusun dalam lima bab dengan pembahasan sebagai berikut.

Bab I Pendahuluan menjelaskan latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika pembahasan sebagai dasar pengerjaan Tugas Akhir.

Bab II Studi Literatur membahas keamanan kode hasil LLM, pemeriksaan dengan SAST dan LLM, sistem multi-agen, perbaikan kode, serta ketahanan reviewer. Bab ini juga membandingkan mekanisme pengambilan keputusan pada penelitian terkait dengan rancangan Evidence-Based Arbiter.

Bab III Analisis dan Perancangan Solusi menguraikan kebutuhan sistem, ruang lingkup bukti, arsitektur gate, peran agen, kebijakan arbiter, dan rancangan evaluasi.

Bab IV Implementasi dan Evaluasi menjelaskan penerapan rancangan, konfigurasi eksperimen, hasil pengujian, serta analisis perbandingan sesuai rumusan masalah.

Bab V Kesimpulan dan Saran merangkum jawaban atas rumusan masalah berdasarkan hasil evaluasi, menyatakan keterbatasan penelitian, dan memberikan saran pengembangan berikutnya.

BAB II
STUDI LITERATUR

Bab ini membahas penelitian dan konsep yang mendukung pengembangan sistem pemeriksaan keamanan kode hasil LLM. Pembahasan dimulai dari keamanan kode yang dihasilkan LLM dan dataset yang digunakan untuk mengujinya. Selanjutnya dibahas pemeriksaan kode dengan SAST, kerja sama beberapa agen, perbaikan kode, serta serangan yang dapat memengaruhi hasil pemeriksaan. Pembahasan dibatasi pada konsep dan hasil penelitian yang berkaitan dengan pemeriksaan kode hasil LLM.

II.1 Keamanan Kode Hasil LLM

II.1.1 Kebenaran dan keamanan kode

Large language model (LLM) dapat digunakan untuk membuat kode dari instruksi bahasa alami. Meskipun kode tersebut dapat dijalankan dan memberikan hasil yang benar, kode belum tentu aman. Sebagai contoh, program dapat menampilkan data sesuai permintaan pengguna, tetapi tidak memeriksa apakah pengguna berhak mengakses data tersebut. Oleh karena itu, keberhasilan program menjalankan tugas dan keamanan program perlu diperiksa secara terpisah.

Untuk mengelompokkan kelemahan kode, dataset yang dibahas pada bab ini menggunakan *Common Weakness Enumeration* (CWE). Setiap CWE menunjukkan suatu jenis kelemahan, seperti pemeriksaan masukan yang tidak memadai atau penggunaan kata sandi di dalam kode. Pengelompokan ini membantu peneliti menentukan jenis kelemahan yang ingin diuji dan membandingkan temuan pada jenis yang sama (Siddiq & Santos, 2022; Tony et al., 2023). Namun, satu program dapat memiliki lebih dari satu kelemahan. Pemeriksaan terhadap satu CWE belum mencakup seluruh masalah keamanan pada program tersebut.

CyberSecEval menilai keamanan LLM dari dua sisi, yaitu kecenderungan menghasilkan kode rentan dan kesediaan membantu serangan siber. Pada pengujian

keluarga Llama 2, Code Llama, dan GPT, sekitar 30% saran kode pada benchmark tersebut dilaporkan rentan. Alat pendeteksi yang digunakan memperoleh presisi 96% dan *recall* 79% berdasarkan pemeriksaan manual (Bhatt et al., 2023). Presisi menunjukkan ketepatan temuan, sedangkan recall menunjukkan seberapa banyak kelemahan yang berhasil ditemukan. Angka kemampuan alat pendeteksi tersebut berbeda dari persentase kode rentan yang dihasilkan model.

Hasil penelitian itu juga menunjukkan bahwa kemampuan membuat kode yang lebih baik tidak selalu diikuti oleh keamanan yang lebih baik. Hal serupa ditemukan pada perbandingan tujuh alat LLM oleh Morkonda dkk. Penelitian tersebut menggunakan 81 prompt Python dari LLMSecEval yang mencakup 12 kategori CWE. Alat yang diuji adalah GPT-4o, Claude 3 Sonnet, Gemini, Perplexity AI, Phind-70b, CodeWhisperer, dan watsonx. Dengan pemeriksaan CodeQL dan GPT-4o untuk kategori tertentu, sedikitnya sekitar 73% potongan kode pada setiap alat dinilai memiliki kerentanan (Morkonda et al., 2026). Angka ini berlaku pada tugas yang dipilih dalam penelitian tersebut, sehingga tidak menggambarkan seluruh penggunaan LLM.

II.1.2 Pengaruh prompt dan cara pengujian

Penelitian keamanan kode umumnya menggunakan prompt yang disiapkan untuk percobaan atau mengambil kode dari penggunaan nyata. Prompt yang disiapkan peneliti memudahkan pengujian karena tugas yang diberikan kepada setiap model dapat dibuat sama. Namun, bentuk tugas tersebut dapat berbeda dari permintaan pengguna dalam kegiatan pengembangan perangkat lunak.

Penelitian pada dataset DevGPT menggunakan 2.315 potongan kode C, C++, dan C# dari percakapan pengembang dengan LLM. Pemindaian kode dan pemeriksaan manual menemukan 56 kerentanan pada 48 berkas. Penelitian tersebut juga menguji GPT-4.1, GPT-5, dan Claude Opus 4.1 untuk mendeteksi serta memperbaiki kelemahan (Belozerov et al., 2026). Berbeda dari pengujian menggunakan prompt keamanan, data DevGPT mencakup kode yang diberikan pengguna dan kode yang dibuat model. Karena sumber data dan cara

pemeriksaannya berbeda, hasilnya tidak dapat langsung dibandingkan dengan persentase kerentanan pada LLMSecEval.

WildCode Revisited juga membahas keamanan kode dari penggunaan ChatGPT yang nyata. Penelitian tersebut menunjukkan bahwa perhatian pengguna terhadap keamanan masih terbatas (Khanmohammadi et al., 2026). Sementara itu, Kharma dkk. menemukan bahwa perubahan cara menyusun prompt dapat mengubah jenis kelemahan yang muncul, tetapi belum memberikan penurunan jumlah atau kepadatan kerentanan yang signifikan secara statistik pada pengujian mereka (Kharma et al., 2026). Dengan demikian, permintaan untuk membuat kode aman tetap perlu diikuti pemeriksaan kode. Hasil pada bahasa lain, seperti C/C++ dalam LLM-CSEC, juga perlu disesuaikan sebelum digunakan untuk menjelaskan keamanan kode Python (Shahid et al., 2025).

Cara menyusun benchmark turut memengaruhi hasil pengujian. Hariharan dkk. menunjukkan bahwa komentar, nama pengenal, dan instruksi pada CyberSecEval dapat memberi petunjuk yang mendorong model menghasilkan pola tidak aman. Ketika petunjuk tersebut diubah, jumlah keluaran yang dinilai aman oleh alat pendeteksi juga berubah (Hariharan et al., 2024). Selain itu, dataset publik mungkin telah muncul dalam data pelatihan model. Hal ini perlu diperhatikan agar kemampuan pada dataset lama tidak langsung dianggap mewakili kemampuan pada kode yang benar-benar baru (Chen et al., 2025).

II.1.3 Dataset penelitian

SecurityEval menyediakan prompt dan contoh kode Python rentan yang dikelompokkan berdasarkan CWE. Pemeriksaan `dataset.jsonl` pada versi repositori `6f4fb70` menghasilkan 121 sampel dengan 69 kategori CWE berdasarkan kolom `ID`. LLMSecEval pada versi `39e97f0` berisi 150 baris tugas dan 18 kategori CWE. Sebanyak 83 baris berlabel Python dan mencakup 12 kategori CWE (Siddiq & Santos, 2022; Tony et al., 2023). Jumlah tersebut menunjukkan isi snapshot dataset, bukan jumlah percobaan penelitian ini.

Kedua dataset menyediakan bentuk tugas yang berbeda, yaitu pelengkapan kode dan pembuatan kode dari instruksi bahasa alami. Keduanya memiliki

12 kategori CWE Python yang sama. Pada LLMSecEval, 83 baris Python menggunakan 81 `Prompt ID` unik karena dua ID dipakai masing-masing dua kali. Isi prompt dan nama berkas pada baris tersebut berbeda. Jumlah 81 ID ini sama dengan jumlah yang dilaporkan Morkonda dkk., tetapi kesamaan hitungan belum membuktikan aturan seleksi yang digunakan penulis. Oleh karena itu, baris dataset dan ID perlu dibedakan agar tugas yang berbeda tidak dihapus hanya karena ID-nya sama (Morkonda et al., 2026; Tony et al., 2023).

CodeSecEval menyediakan pembanding yang menggabungkan pengujian fungsi dan keamanan. Versi tahun 2024 memuat 180 sampel dan 44 jenis kerentanan, sedangkan revisi September 2026 memuat 255 tugas Python dengan 77 CWE (Wang et al., 2024; Wang et al., 2026a). Revisi tersebut memperkenalkan SecAwareCoder yang menghubungkan pemodelan ancaman sesuai tugas, pembuatan kode dengan batasan keamanan, pembuatan pengujian, dan perbaikan berdasarkan hasil eksekusi. Dataset revisi telah tersedia di Hugging Face. Namun, pada pemeriksaan 20 Oktober 2026, repositori resmi menyatakan bahwa kode SecAwareCoder belum dirilis. Pembandingan metode karena itu dibedakan dari replikasi implementasinya.

II.2 Pemeriksaan Kerentanan dengan SAST dan LLM

II.2.1 Pemeriksaan kode secara statis

Static application security testing (SAST) adalah pemeriksaan keamanan kode tanpa menjalankan program. Pemeriksaan dapat dilakukan dengan mencari pola tertentu, memeriksa struktur kode, atau mengikuti aliran data. Sebagai contoh, alat dapat memeriksa apakah masukan pengguna dipakai dalam perintah basis data tanpa penanganan yang sesuai. Pendekatan ini memungkinkan masalah ditemukan sebelum program digunakan.

Meskipun demikian, hasil SAST masih dapat keliru. Alat dapat memberi peringatan pada kode yang sebenarnya tidak rentan, yang disebut *false positive*. Sebaliknya, kelemahan yang tidak ditemukan disebut *false negative*. Kesalahan dapat terjadi ketika alat tidak memahami fungsi pustaka, pemeriksaan masukan buatan pengembang, atau hubungan antarbagian program (Iranmanesh et al., 2025;

Li et al., 2025a). Oleh karena itu, peringatan dari alat perlu diperiksa bersama konteks kode.

Setiap alat juga memiliki cakupan aturan yang berbeda. Kode yang tidak diberi peringatan oleh Bandit masih mungkin ditandai oleh CodeQL, sebagaimana dibahas dalam Multi-LLMSecCodeEval (Sabir et al., 2026). Pada penelitian ini, penggunaan Semgrep dan Bandit perlu disertai catatan versi serta aturan yang digunakan. Hasil tanpa peringatan juga perlu dibedakan dari kegagalan membaca kode atau tidak tersedianya aturan untuk suatu CWE. Ketiga keadaan tersebut memiliki arti yang berbeda bagi keputusan gate.

II.2.2 Penggunaan LLM untuk memeriksa hasil SAST

LLM dapat digunakan untuk membantu memahami konteks yang sulit ditangani aturan statis. Salah satu bentuknya adalah pendekatan *neuro-symbolic*, yaitu penggabungan kemampuan model dalam memahami kode dengan analisis berbasis aturan. IRIS menggunakan LLM untuk membantu menentukan sumber data, bagian kode yang menerima data, dan konteks pemakaiannya dalam CodeQL. Pada versi ICLR 2025, IRIS dengan GPT-4 mendeteksi 55 dari 120 kerentanan dalam CWE-Bench-Java, dibandingkan 27 yang ditemukan CodeQL. Rata-rata *false discovery rate*, yaitu proporsi temuan yang dinilai salah menurut ukuran penelitian tersebut, turun dari 90,03% menjadi 84,82% (Li et al., 2025a).

LLM juga dapat diberi tugas yang lebih terbatas, yaitu memeriksa peringatan yang sudah ditemukan alat. Proses ini disebut triase. ZeroFalse menyediakan jejak aliran data, konteks kode, dan informasi CWE kepada LLM untuk membantu menentukan apakah suatu peringatan perlu dipertahankan. Pengujiannya mencakup OWASP Java Benchmark dan proyek nyata (Iranmanesh et al., 2025). SAST-Genius menggabungkan Semgrep 1.97.0 dengan Llama 3 8B yang telah di-fine-tune. Pengujiannya memakai 25 repositori Python, Java, dan JavaScript, dengan 170 kerentanan acuan. Dalam laporan penulis, false positive turun dari 225 menjadi 20 (Agrawal & Ahi, 2025). Angka tersebut berasal dari pengujian campuran bahasa dan tidak langsung menunjukkan besarnya peningkatan pada kode Python hasil LLM.

QASecClaw menggunakan pembagian tugas yang serupa. Semgrep menghasilkan temuan awal, lalu agen filter berbasis Qwen 3.5 Plus memeriksa temuan tersebut bersama kode. Pada 2.740 kasus Java dalam OWASP Benchmark v1.2, jumlah false positive turun dari 560 menjadi 64, tetapi recall juga sedikit menurun. Sistemnya menyediakan bagian untuk menggabungkan bukti pengujian dinamis, tetapi bagian tersebut tidak dijalankan pada percobaan benchmark statis (Ameen et al., 2026). Dengan demikian, keberadaan komponen pengujian dalam rancangan belum berarti seluruh temuan telah dibuktikan melalui eksekusi kode.

Berbeda dari penyaringan peringatan, QRS menggunakan LLM untuk membentuk kueri CodeQL dan memeriksa temuannya pada paket Python utuh (Tsigkourakos & Patsakis, 2026). Paket utuh menyediakan konteks yang lebih lengkap daripada sebuah fungsi atau potongan kode. Perbedaan ini perlu diperhatikan ketika cara kerja QRS diterapkan pada kode hasil LLM. Sebagian besar penelitian tersebut memakai kode proyek atau benchmark yang telah tersedia, sehingga hasilnya masih perlu diuji pada kode baru yang dibuat model.

II.2.3 Peran SAST dalam pengambilan keputusan

Dalam rancangan penelitian ini, agen Analyse memeriksa kode dengan bantuan Semgrep dan Bandit. Agen Triage kemudian menilai apakah temuan tersebut sesuai dengan kondisi kode. Pemisahan tugas ini diperlukan karena menemukan pola yang mencurigakan dan memutuskan kebenaran suatu temuan merupakan dua pekerjaan berbeda. Hasil pemeriksaan perlu memuat lokasi, jenis CWE, tingkat keparahan, aturan asal, dan alasan yang mendukung temuan.

Jika beberapa alat melaporkan masalah yang sama, temuan perlu digabungkan agar satu kelemahan tidak dihitung berulang. Setiap hasil juga perlu dihubungkan dengan versi kode yang diperiksa. Setelah kode diperbaiki, hasil pemeriksaan versi sebelumnya tidak dapat langsung digunakan untuk menerima versi baru. Penjelasan LLM dapat membantu memahami masalah, tetapi tetap perlu dibedakan dari bukti hasil pengujian.

Penilaian triase perlu dibedakan dari keputusan penerimaan kode. QASecClaw menunjukkan bahwa penyaringan peringatan dapat menurunkan false

positive sekaligus mengurangi recall (Ameen et al., 2026). Karena itu, penolakan suatu temuan perlu disertai alasan dan bukti yang dapat ditelusuri. Aturan tingkat keparahan dan tindak lanjut merupakan bagian dari rancangan gate yang perlu dinilai dalam percobaan.

II.3 Sistem Multi-Agen untuk Keamanan Kode

II.3.1 Pembagian tugas antaragen

Sistem multi-agen membagi pekerjaan kepada beberapa agen yang saling bertukar informasi. Dalam pemeriksaan keamanan kode, agen dapat bertugas membuat kode, mencari kelemahan, menguji temuan, atau memperbaiki kode. Pembagian ini membantu setiap agen berfokus pada tugas tertentu. Namun, manfaatnya tetap bergantung pada cara agen bekerja sama dan bagaimana hasilnya diperiksa.

Tujuan sistem perlu dibedakan sebelum hasil penelitian dibandingkan. CodeAgent digunakan untuk membantu proses peninjauan kode, sedangkan VulTrial dan MAVUL lebih berfokus pada pemeriksaan kerentanan pada kode yang sudah tersedia (Li et al., 2025b; Tang et al., 2024; Widyasari et al., 2025). Sistem yang berhasil mengenali kelemahan belum tentu sudah mengatur pembuatan kode, perbaikannya, dan keputusan apakah kode dapat diterima. Perbedaan tugas ini menjadi dasar dalam memilih pembanding untuk penelitian ini.

Beberapa agen dapat menggunakan model yang sama dengan instruksi berbeda. Pilihan lainnya adalah menggunakan model yang berbeda untuk setiap tugas. Instruksi yang berbeda dapat mengarahkan perhatian agen pada bagian kode yang berbeda, tetapi tidak menjamin pendapatnya saling bebas. Jika agen memiliki kelemahan pemahaman yang sama, beberapa agen dapat menghasilkan kesalahan yang sama pula. Karena itu, manfaat penambahan agen perlu dilihat dari perubahan hasil pemeriksaan, bukan dari banyaknya pendapat yang dihasilkan.

II.3.2 Pembuatan, pemeriksaan, dan pengujian kode

AutoSafeCoder menggabungkan tiga agen, yaitu Coding Agent, Static Analyzer Agent, dan Fuzzing Agent. Agen pembuat kode menerima masukan dari pemeriksaan keamanan, kemudian memperbaiki hasilnya. Pada metode versi

pertama, Static Analyzer Agent adalah LLM yang diarahkan untuk mencari kelemahan berdasarkan CWE. Bandit digunakan untuk menilai hasil percobaan, sehingga perannya berbeda dari reviewer LLM dalam sistem tersebut.

Dengan GPT-4o, jumlah kode rentan pada SecurityEval turun dari 59/121 menjadi 44/121. Selisihnya sekitar 12,4 poin persentase berdasarkan jumlah sampel. Angka penurunan 13% dalam paper tidak digunakan sebagai penurunan relatif. Sementara itu, skor pass@1 pada HumanEval turun dari 0,9085 menjadi 0,8780 (Nunez et al., 2024). Hasil ini menunjukkan adanya perbaikan keamanan yang disertai sedikit penurunan keberhasilan fungsi. Pengujian fuzzing memeriksa kegagalan saat kode dijalankan, tetapi tidak semua kelemahan keamanan menimbulkan kegagalan yang sama.

Multi-LLMSecCodeEval membandingkan sepuluh alur yang mencakup pembuatan kode, deteksi kerentanan, dan perbaikan. Pada SecLLMEval serta SecLLMHolmes, penggabungan beberapa model, CodeQL, dan pemeriksaan lintas-model dilaporkan memberikan hasil yang lebih konsisten daripada kerja sama LLM tanpa alat statis (Sabir et al., 2026). Penelitian tersebut sudah membahas alur dari pembuatan hingga perbaikan kode. Oleh karena itu, alur tersebut tidak dijadikan kebaruan tersendiri dalam penelitian ini. Hasil untuk kelompok model besar dan percobaan model lebih kecil dibahas sebagai konfigurasi berbeda, sehingga persentasenya tidak digabungkan menjadi satu hasil.

Hasil tersebut juga menunjukkan perlunya memisahkan manfaat alat dari manfaat kerja sama agen. Jika pemindai dan beberapa reviewer ditambahkan sekaligus, peningkatan hasil belum tentu berasal dari diskusi antaragen. Penelitian ini karena itu merencanakan pembanding berupa LLM tunggal, SAST saja, serta SAST dengan LLM. Tugas, jumlah kesempatan perbaikan, dan anggaran penggunaan model perlu dibuat sebanding atau dijelaskan perbedaannya.

II.3.3 Penggabungan hasil pemeriksaan

Salah satu cara menggabungkan hasil adalah voting mayoritas, yaitu memilih keputusan yang paling banyak diberikan agen. Cara ini mudah diterapkan, tetapi dapat menghasilkan keputusan salah jika sebagian besar agen memiliki

kesalahan yang sama. Cara lain adalah debat, yaitu meminta agen membahas perbedaan pendapat sebelum mengambil kesimpulan.

ReasonVul menggunakan tiga cara penalaran, yaitu deduktif, induktif, dan abduktif. Secara sederhana, agen memeriksa kode berdasarkan aturan umum, pola dari contoh, dan dugaan penyebab masalah. Ketiga tugas tersebut menggunakan Phi4, Llama4, dan DeepSeek. Ketika hasilnya berbeda, agen melakukan debat. Pada analisis konflik dalam percobaan PrimeVul, 389 dari 542 konflik diselesaikan dengan benar. Pada JITVUL, sistem memperoleh PairAcc 28,67% (Peng et al., 2026). PairAcc menghitung keberhasilan mengenali kode rentan dan versi perbaikannya secara benar sebagai satu pasangan. Ukuran ini berbeda dari akurasi untuk satu potongan kode.

VulTrial menggunakan pembagian peran seperti ruang sidang. Peneliti keamanan mengajukan dugaan kelemahan, penulis kode memberikan penjelasan, lalu moderator dan review board menilai pembahasannya (Widyasari et al., 2025). MAVUL menggunakan analis konteks dan arsitek keamanan dengan GPT-4o. Agen evaluasinya memakai label acuan untuk menilai hasil eksperimen (Li et al., 2025b). Agen tersebut berbeda dari arbiter saat penggunaan gate, yang harus mengambil keputusan tanpa mengetahui label jawaban. Kedua pendekatan memberi contoh cara mempertanyakan temuan sebelum menerimanya.

Debat tidak selalu menghasilkan keputusan yang benar. Refute-or-Promote menggunakan pemeriksaan bertahap, kritik dari model lain, dan pengujian nyata untuk menolak temuan yang keliru. Laporan kasusnya menunjukkan bahwa kesepakatan beberapa reviewer masih dapat dibantah oleh hasil pengujian (Agarwal, 2026). Wynn dkk. juga menemukan bahwa agen dapat beralih dari jawaban benar ke jawaban salah setelah menerima alasan dari agen lain (Wynn et al., 2025). Karena itu, persetujuan banyak agen tidak menggantikan kebutuhan akan bukti.

II.3.4 Evidence-Based Arbiter

Arbiter adalah bagian yang menentukan keputusan akhir berdasarkan hasil pemeriksaan. Dalam penelitian ini, *Evidence-Based Arbiter* merupakan nama komponen yang direncanakan menggunakan hasil SAST, hasil pengujian, dan

konfirmasi Validation sebagai dasar keputusan. Bukti SAST berupa peringatan perlu dibedakan dari kelemahan yang berhasil dikonfirmasi melalui pengujian. Validation memeriksa kesesuaian bukti, kemudian arbiter non-LLM menerapkan aturan keamanan yang disimpan dalam YAML.

ReasonVul menggabungkan penilaian agen melalui kesepakatan dan debat. Jika seluruh agen sepakat, hasilnya diterima. Jika kesepakatan belum tercapai sampai batas ronde, metode tersebut menetapkan hasil tidak rentan (Peng et al., 2026). Pada gate yang direncanakan, bukti yang bertentangan atau pemeriksaan wajib yang belum selesai diarahkan untuk ditinjau manusia. Pengaruhnya terhadap kode rentan yang lolos dan banyaknya kode yang ditahan perlu dibandingkan.

VulTrial menyerahkan keputusan kepada review board berbasis LLM setelah pembahasan antaragen. Metode tersebut juga memakai ambang keputusan: fungsi dinilai rentan ketika terdapat temuan yang dinyatakan valid, berkeparahan tinggi, dan memerlukan perbaikan segera (Widyasari et al., 2025). Pada Evidence-Based Arbiter, penjelasan agen menjadi masukan bagi aturan program yang juga menerima hasil alat dan pengujian.

QASecClaw lebih dekat dari sisi penggunaan hasil SAST. Ketika LLM gagal, mengalami timeout, atau menghasilkan respons yang tidak valid, temuan SAST tetap dipertahankan (Ameen et al., 2026). Kebijakan tersebut menjaga agar kegagalan reviewer tidak menghapus peringatan. Evidence-Based Arbiter menerapkan aturan pada penerimaan kode dan tindak lanjutnya: diteruskan, diperbaiki, atau ditinjau manusia. Mempertahankan peringatan perlu dibedakan dari keputusan menerima kode.

Refute-or-Promote juga mensyaratkan bukti hasil pengujian sebelum temuan dilaporkan kepada pengelola perangkat lunak. Perpindahan tahap dikelola agen orkestrator, dengan peninjauan manusia terhadap temuan akhir (Agarwal, 2026). Sementara itu, AutoSafeCoder sudah menghubungkan pemeriksaan dan perbaikan kode melalui umpan balik agen (Nunez et al., 2024). Rancangan penelitian ini menggunakan aturan penerimaan kode hasil generasi yang

menghubungkan bukti pemeriksaan dengan keputusan serta pemeriksaan ulang setelah patch.

Arbiter menentukan *pass*, *revise*, atau *block*. Pass berarti kode memenuhi syarat pemeriksaan wajib. Revise berarti kode perlu diperbaiki dan diperiksa ulang. Block berarti kode ditahan untuk ditinjau manusia. Menurut rancangan awal, Triage tidak dapat sendirian membatalkan temuan SAST berkeparahan tinggi yang belum diselesaikan. Aturan ini perlu diuji karena dapat menahan kode rentan sekaligus menambah kasus yang sebenarnya tidak rentan untuk ditinjau.

Kode yang diterima dapat diberi label *Verified*, dengan arti telah melewati pemeriksaan yang ditetapkan. Label tersebut bukan jaminan bahwa kode bebas dari seluruh kelemahan. Alasan keputusan perlu mencatat aturan, versi kode, dan bukti yang digunakan. Setelah kode berubah, bukti dari versi sebelumnya perlu diperbarui melalui pemeriksaan ulang.

Berdasarkan perbandingan tersebut, kontribusi yang diusulkan terletak pada aturan penggabungan bukti dan penanganan hasil yang bertentangan dalam gate. Evaluasinya juga mencakup pengaruh sanitizer dan manipulasi reviewer terhadap keputusan akhir. Manfaat rancangan ini perlu ditunjukkan melalui pengujian; nama Evidence-Based Arbiter dan penggunaan YAML sendiri tidak menunjukkan peningkatan keamanan.

II.3.5 Biaya penggunaan model

Penggunaan beberapa model juga menambah biaya. Wang menggabungkan model layanan dengan pemeriksa lokal untuk menyeimbangkan hasil deteksi dan biaya (Wang, 2026). Pada gate, biaya tidak hanya berasal dari pembuatan kode. Pemeriksaan, diskusi, pembuatan pengujian, dan perbaikan berulang turut memakai token serta waktu. Menjalankan beberapa agen bersamaan dapat memperpendek waktu tunggu, tetapi tidak selalu mengurangi jumlah penggunaan model.

II.4 Perbaikan Kode Otomatis

II.4.1 Perbaikan berdasarkan hasil pemeriksaan

Perbaikan kode otomatis bertujuan menghilangkan kelemahan tanpa mengubah fungsi yang dibutuhkan pengguna. Sebuah perubahan belum dapat

dianggap berhasil hanya karena peringatan alat hilang. Model dapat saja menghapus bagian kode yang bermasalah, tetapi sekaligus menghilangkan fungsi program. Oleh karena itu, kode yang telah diperbaiki perlu diperiksa kembali dari sisi keamanan dan kebenaran hasilnya.

Salah satu cara memperbaiki kode adalah memberikan hasil analisis statis kepada LLM. Feedback-Driven Security Patching menggunakan keluaran Bandit untuk mengarahkan perbaikan kode Python (Alrashedy et al., 2024). Static Analysis as a Feedback Loop juga menggunakan Bandit dan Pylint untuk memperbaiki beberapa aspek kualitas kode (Blyth et al., 2025). Pada kedua pendekatan tersebut, model memperoleh informasi tentang masalah yang ditemukan alat. Informasi ini membantu model melakukan perbaikan yang lebih terarah daripada hanya diminta memeriksa jawabannya sendiri.

Penggunaan beberapa sumber masukan dibahas dalam penelitian Sriram dkk. Model menerima hasil kompilasi GCC, pemeriksaan CodeQL, dan pengujian dengan KLEE. Pada 1.720 program C/C++ hasil CodeLlama-7B, tingkat cacat keamanan menurut CodeQL turun dari 58,55% menjadi 22,19%. Percobaan lainnya menggunakan 1.522 program hasil DeepSeek-Coder-1.3B (Sriram et al., 2026). Hasil ini mendukung penggunaan alat untuk membantu perbaikan, tetapi alat pengujian C/C++ tersebut tidak dapat langsung digunakan pada potongan kode Python.

LLMLOOP menghubungkan perbaikan kode dengan perbaikan pengujiannya melalui beberapa tahap umpan balik (Ravi et al., 2025). Pengujian mempunyai peran penting karena membantu memeriksa apakah perubahan kode tetap memenuhi tugas semula. Hilangnya peringatan pada satu alat tidak cukup untuk menjelaskan seluruh hasil perbaikan. Alat yang digunakan, jenis kelemahan yang diperiksa, dan pengujian fungsi perlu dijelaskan bersama.

II.4.2 Pemisahan agen perbaikan

Model yang membuat kode dapat diminta memperbaiki keluarannya sendiri. Cara ini disebut *self-repair*. Pilihan lainnya adalah menggunakan agen Fixer yang terpisah dari generator. Model lain dapat memberikan cara penyelesaian berbeda,

tetapi tetap mungkin memiliki kesalahan yang sama. Olausson dkk. menunjukkan bahwa manfaat self-repair bergantung pada kualitas umpan balik dan biaya percobaan (Olausson et al., 2024). Oleh karena itu, penggunaan model berbeda perlu dibandingkan dengan model yang sama pada tugas dan anggaran yang sebanding.

Model juga dapat menerima contoh perbaikan dari penyimpanan pengetahuan atau *knowledge store*. Pengambilan contoh yang sesuai disebut *retrieval*. AutoPatch menggunakan informasi CVE untuk membantu pemeriksaan dan perbaikan, sedangkan penelitian multi-tool menyimpan hasil perbaikan yang telah lolos pengujian agar dapat digunakan kembali (Seo et al., 2025; Sriram et al., 2026).

Penyimpanan contoh perbaikan memerlukan pemisahan antara contoh yang boleh diambil model dan sampel untuk penilaian akhir. Jika patch sampel uji yang sama tersedia dalam retrieval, hasil pengujian tidak lagi menunjukkan kemampuan pada kasus yang belum diketahui. Setiap contoh juga perlu dikaitkan dengan versi kode dan bukti pengujian. Keberhasilan pada satu kasus belum menjamin bahwa patch tersebut sesuai untuk kasus lain.

II.4.3 Pemeriksaan ulang dan batas perbaikan

Perbaikan dapat menimbulkan masalah baru pada bagian yang sebelumnya tidak bermasalah. Keadaan ini disebut regresi. Studi pada perbaikan Infrastructure-as-Code menunjukkan bahwa hasil pemeriksaan keamanan dapat memburuk setelah perubahan kode. Penulis juga membedakan regresi yang benar-benar terjadi dari perubahan hasil ukur akibat penataan ulang sumber daya (Agyekum & Santos, 2026). Temuan pada Terraform tersebut tidak langsung menunjukkan tingkat risiko pada Python, tetapi menjelaskan alasan perlunya pemeriksaan ulang setelah perubahan.

Patch perlu melalui kembali pemeriksaan yang berlaku. Pengujian yang sebelumnya menemukan masalah dapat dipertahankan untuk memeriksa apakah masalah itu muncul kembali. Pengujian fungsi juga diperlukan agar model tidak menghilangkan tugas program saat memperbaiki kelemahan. Untuk fungsi atau potongan kode, pengujian dapat membutuhkan program pembantu atau *test harness*

yang menyiapkan masukan dan memeriksa hasil. CodeSecEval memberi contoh penyediaan pengujian fungsi dan keamanan, sedangkan jalur dinamis QASecClaw tidak dijalankan pada evaluasi statisnya (Ameen et al., 2026; Wang et al., 2026a). Dengan demikian, kemampuan eksekusi perlu diperiksa untuk setiap tugas.

Jumlah perbaikan perlu dibatasi agar proses tidak terus mengulang perubahan yang tidak menyelesaikan masalah. Jika batas tercapai, kode tidak langsung diterima. Arbiter menentukan tindak lanjut sesuai masalah yang masih tersisa. Begitu pula, kode yang belum dapat dijalankan tidak boleh dianggap telah lulus pengujian dinamis hanya karena tidak ada laporan kegagalan.

II.5 Ketahanan Gate terhadap Serangan

II.5.1 Serangan pada agen pemeriksa

Agen pemeriksa atau *reviewer* LLM membaca kode dan informasi pendukung untuk menilai keamanan. Informasi tersebut dapat berasal dari pihak yang tidak tepercaya. Penyerang dapat menyisipkan instruksi dalam komentar, docstring, atau teks lain agar model mengabaikan kelemahan. Upaya mengalihkan model melalui instruksi semacam ini disebut *prompt injection*. Pada gate, serangan dapat bertujuan menyembunyikan temuan, menurunkan tingkat keparahan, atau membuat kode rentan memperoleh keputusan pass.

Serangan perlu dibedakan berdasarkan tugas model yang disasar. TAPI menggunakan pemicu dalam komentar untuk memengaruhi kode yang dibuat model (Yang et al., 2024). Your AI, My Shell membahas pengalihan editor agentik melalui sumber pengembangan yang telah disisipi instruksi penyerang (Liu et al., 2026). Kedua penelitian tersebut menunjukkan risiko dari masukan tidak tepercaya, tetapi tugasnya berbeda dari pemeriksaan keamanan kode. Hasil serangan pada generator atau editor tidak langsung menunjukkan tingkat keberhasilan serangan pada reviewer.

Batas kemampuan penyerang memengaruhi hasil pengujian. Penyerang yang hanya dapat mengubah komentar memiliki akses berbeda dari penyerang yang dapat mengubah perintah program, keluaran alat, atau isi knowledge store.

Penelitian prompt injection membedakan instruksi pengembang dari masukan tidak tepercaya yang dibaca model (Greshake et al., 2023; Liu et al., 2024). Oleh karena itu, vektor serangan dan akses penyerang perlu dinyatakan sebelum hasil ketahanan dibandingkan.

II.5.2 Hasil penelitian serangan pada reviewer

Maloyan dan Namiot menunjukkan bahwa penilaian LLM dapat dipengaruhi oleh prompt injection. Mereka membahas penggunaan beberapa model penilai dan penilaian komparatif sebagai arah pertahanan (Maloyan & Namiot, 2025). Namun, tugas penilaian umum tidak sama dengan pencarian kelemahan kode. Beberapa model juga dapat membaca instruksi penyerang yang sama. Oleh karena itu, penambahan reviewer tetap perlu diuji dan belum dapat dianggap cukup untuk mencegah serangan.

Hasil yang berbeda ditemukan dalam penelitian Thornton. Percobaan menggunakan 100 sampel kode rentan dari Python, JavaScript, dan Java yang dinilai oleh delapan model komersial maupun terbuka. Pengaruh komentar serangan tidak signifikan secara statistik pada pengujian berpasangan. Penghapusan komentar justru menurunkan kemampuan deteksi model yang lebih lemah. Sebaliknya, pemberian temuan SAST sebagai petunjuk membantu pemeriksaan (Thornton, 2026). Hasil tersebut berlaku pada sampel dan jenis komentar yang diuji, sehingga tidak berarti reviewer kebal terhadap seluruh serangan.

Perbedaan hasil ini menunjukkan pentingnya mempertahankan tugas utama ketika menilai pertahanan. Sistem perlu tetap mampu membaca konteks yang dibutuhkan untuk memeriksa kode. Tinjauan ancaman agen juga menekankan bahwa perlindungan, kegunaan, dan waktu pemrosesan perlu dinilai bersama (Wang et al., 2026b). Pertahanan yang membuat model mengabaikan semua informasi tambahan dapat mengurangi serangan, tetapi juga dapat mengurangi kemampuannya menyelesaikan tugas.

II.5.3 Sanitizer dan aturan keputusan

Sanitizer adalah bagian non-LLM yang menyiapkan masukan sebelum dibaca reviewer, misalnya dengan mengurangi komentar yang mengandung

instruksi pengalih. Penghapusan informasi belum tentu membantu, sebagaimana ditemukan Thornton pada model yang lebih lemah (Thornton, 2026). Pada Python, docstring juga dapat diakses melalui atribut `__doc__` saat program berjalan (Python Software Foundation, n.d.). Karena itu, penghapusan docstring tidak dapat selalu dianggap mempertahankan perilaku program. Proyeksi untuk reviewer perlu dibedakan dari kode asli yang dipindai dan dijalankan, serta tetap menyimpan hubungan nomor baris.

Manfaat sanitizer akan dinilai dengan membandingkan gate yang menggunakannya dan gate yang tidak menggunakannya. Pengujian memakai sampel yang sama, baik tanpa serangan maupun setelah disisipi serangan. Kelemahan kode harus tetap ada pada kedua sampel. Jika perubahan komentar sekaligus menghilangkan kelemahan atau mengubah fungsi program, perbedaan keputusan reviewer tidak lagi menunjukkan pengaruh serangan pada kasus yang sama.

Selain keberhasilan serangan, pengujian perlu mencatat perubahan presisi, recall, dan jumlah kode rentan yang diterima. *Attack success rate* adalah proporsi serangan yang mencapai tujuan pada kasus yang diuji. Perhitungannya perlu menjelaskan kasus mana yang masuk ke penyebut. Kelemahan yang memang tidak terdeteksi sejak awal perlu dibedakan dari kelemahan yang baru terlewat setelah komentar serangan ditambahkan.

Aturan arbiter dapat membatasi keputusan reviewer, tetapi serangan juga dapat berada di luar komentar. PhantomSkill menunjukkan bahwa perilaku berbahaya dapat disamarkan dalam kode yang tampak memiliki kelemahan biasa (Lin & Yu, 2026). Karena itu, ruang lingkup perlindungan perlu menyebutkan masukan yang diperiksa dan komponen yang dapat diubah penyerang. Hasil pertahanan komentar tidak langsung berlaku untuk aturan gate, keluaran alat, atau penyimpanan pengetahuan.

BAB III

ANALISIS DAN PERANCANGAN SOLUSI

III.1 Analisis Masalah

Bab ini menguraikan hasil analisis yang lebih mendalam tentang persoalan tugas akhir yang diangkat.

III.2 Kebutuhan Sistem

Kebutuhan sistem mencakup kebutuhan fungsional dan non-fungsional:

1. **Kebutuhan Fungsional (F)**: Fungsionalitas inti yang harus disediakan oleh perangkat lunak.
2. **Kebutuhan Non-Fungsional (NF)**: Kriteria kualitas sistem seperti performa, keandalan, dan keamanan.

III.3 Perancangan Arsitektur

Jelaskan perancangan arsitektur sistem secara menyeluruh, aliran data, serta modul-modul utama yang dibangun.

BAB IV
IMPLEMENTASI DAN EVALUASI

IV.1 Lingkungan Implementasi

Jelaskan spesifikasi lingkungan perangkat keras, perangkat lunak, pustaka, dan kakas yang digunakan dalam pengembangan sistem.

IV.2 Prosedur dan Skenario Pengujian

Jelaskan bagaimana pengujian atau eksperimen dirancang untuk mengukur pencapaian tujuan tugas akhir.

IV.3 Hasil Pengujian dan Diskusi

Tampilkan data-data hasil evaluasi beserta analisis pembanding terhadap solusi pembanding (*baseline*).

BAB V
KESIMPULAN DAN SARAN

V.1 Kesimpulan

Kesimpulan menjawab setiap poin tujuan tugas akhir yang telah dinyatakan pada BAB I berdasarkan temuan empiris pada BAB IV.

V.2 Saran

Saran memuat rekomendasi konkret untuk pengembangan atau penelitian lanjutan di masa mendatang.

DAFTAR PUSTAKA

Agarwal, A. (2026). *Refute-or-Promote: An Adversarial Stage-Gated Multi-Agent Review Methodology for High-Precision LLM-Assisted Defect Discovery*. https://arxiv.org/abs/2604.19049

Agrawal, V., & Ahi, K. (2025). *LLM-Driven SAST-Genius: A Hybrid Static Analysis Framework for Comprehensive and Actionable Security*. https://arxiv.org/abs/2509.15433

Agyekum, B., & Santos, F. (2026). Does Fixing Break Security? An Empirical Study of Security Degradation in Iterative LLM-Driven Infrastructure-As-Code Repair. *20th International Symposium on Empirical Software Engineering and Measurement (ESEM 2026), Leibniz International Proceedings in Informatics*, *394*, 50:1–50:20. https://doi.org/10.4230/LIPIcs.ESEM.2026.50

Al Mamun, S. M. A., Islam, A., & Ameen, M. R. (2026). *Beyond QASecClaw: Agent Scaling, Verifier Feedback, and Evidence Reliability in Software Assurance*. https://arxiv.org/abs/2610.36947v1

Alrashedy, K., Aljasser, A., Tambwekar, P., & Gombolay, M. (2024). *Can LLMs Patch Security Issues?*. https://arxiv.org/abs/2312.00024

Ameen, M. R., Alam, M. T. U., & Islam, A. (2026). *QASecClaw: A Multi-Agent LLM Approach for False Positive Reduction in Static Application Security Testing*. https://arxiv.org/abs/2605.01885

Belozerov, V., Barclay, P. J., & Sami, A. (2026). Secure Coding with AI – From Detection to Repair. *Empirical Software Engineering*, *31*. https://doi.org/10.1007/s10664-026-10812-8

Bhatt, M., Chennabasappa, S., Nikolaidis, C., Wan, S., Evtimov, I., Gabi, D., Song, D., Ahmad, F., Aschermann, C., Fontana, L., Frolov, S., Giri, R. P., Kapil, D., Kozyrakis, Y., LeBlanc, D., Milazzo, J., Straumann, A., Synnaeve,

G., Vontimitta, V., … Saxe, J. (2023). *Purple Llama CyberSecEval: A Secure Coding Benchmark for Language Models*. https://arxiv.org/abs/2312.04724v1

Blyth, S., Licorish, S. A., Treude, C., & Wagner, M. (2025). *Static Analysis as a Feedback Loop: Enhancing LLM-Generated Code Beyond Correctness*. https://arxiv.org/abs/2508.14419

Chen, Y., Sun, W., Fang, C., Chen, Z., Ge, Y., Han, T., Zhang, Q., Liu, Y., Chen, Z., & Xu, B. (2025). *Security of Language Models for Code: A Systematic Literature Review*. https://arxiv.org/abs/2410.15631

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). *Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection*. https://arxiv.org/abs/2302.12173

Hariharan, S., Majid, Z. A., Veuthey, J. R., & Haimes, J. (2024). *Rethinking CyberSecEval: An LLM-Aided Approach to Evaluation Critique*. https://arxiv.org/abs/2411.08813

Iranmanesh, M., Sabet, S. M., Marefat, S., Ghasr, A. J., Wilson, A., Sharafaldin, I., & Tayebi, M. A. (2025). *ZeroFalse: Improving Precision in Static Analysis with LLMs*. https://arxiv.org/abs/2510.02534v1

Khanmohammadi, K., Roy, P., Khoury, R., Hamou-Lhadj, A., Konan, W. P., Da Re, A., & Melo, N. R. (2026). *WildCode Revisited: A Comprehensive Empirical Study on the Security of LLM-Generated Code*. https://arxiv.org/abs/2512.04259

Kharma, M., Sabbah, A., Alkhanafseh, M., Hammoudeh, M., & Mohaisen, D. (2026). *An Empirical Evaluation of LLM-Generated Code Security Across Prompting Methods*. https://arxiv.org/abs/2605.24298

Li, Y., Joshi, K., Wang, X., & Wong, E. (2025b). *MAVUL: Multi-Agent Vulnerability Detection via Contextual Reasoning and Interactive Refinement*. https://arxiv.org/abs/2510.00317v1

Li, Z., Dutta, S., & Naik, M. (2025a,). IRIS: LLM-Assisted Static Analysis for Detecting Security Vulnerabilities. *International Conference on Learning Representations*. https://proceedings.iclr.cc/paper_files/paper/2025/hash/582d4e27fa24168f3af1f4582655034b-Abstract-Conference.html

Lin, Y.-T., & Yu, C.-M. (2026). *PhantomSkill: Malicious Code Injection in Agent Skill Ecosystems*. https://arxiv.org/abs/2606.19191

Liu, Y., Zhao, Y., Lyu, Y., Zhang, T., Wang, H., & Lo, D. (2026). *"Your AI, My Shell": Demystifying Prompt Injection Attacks on Agentic AI Coding Editors*. https://arxiv.org/abs/2509.22040

Liu, Y., Jia, Y., Geng, R., Jia, J., & Gong, N. Z. (2024). Formalizing and Benchmarking Prompt Injection Attacks and Defenses. *33rd USENIX Security Symposium (USENIX Security 24)*, 1831–1847. https://www.usenix.org/conference/usenixsecurity24/presentation/liu-yupei

Maloyan, N., & Namiot, D. (2025). *Adversarial Attacks on LLM-as-a-Judge Systems: Insights from Prompt Injections*. https://arxiv.org/abs/2504.18333

Morkonda, S. G., Selim, M., & Assal, H. (2026). *Security of LLM-generated Code: A Comparative Analysis*. https://arxiv.org/abs/2605.23091

Nunez, A., Islam, N. T., Jha, S., & Rad, P. (2024). *AutoSafeCoder: A Multi-Agent Framework for Securing LLM Code Generation through Static Analysis and Fuzz Testing*. https://arxiv.org/abs/2409.10737v1

Olausson, T. X., Inala, J. P., Wang, C., Gao, J., & Solar-Lezama, A. (2024). *Is Self-Repair a Silver Bullet for Code Generation?*. https://arxiv.org/abs/2306.09896

Peng, X., Lin, B., Wang, J., Li, X., Ma, J., Yu, J., Mao, X., & Wang, S. (2026). Three Heads Are Better Than One: A Multi-perspective Reasoning Framework for Enhanced Vulnerability Detection. *Proceedings of the ACM on Software Engineering*, *3*(FSE), 4323–4346. https://doi.org/10.1145/3808197

Python Software Foundation. (n.d.). *Data model: Callable types / user-defined functions*. Retrieved October 20, 2026, from https://docs.python.org/3.11/reference/datamodel.html#user-defined-functions

Ravi, R., Bradshaw, D., Ruberto, S., Jahangirova, G., & Terragni, V. (2025). LLMLOOP: Improving LLM-Generated Code and Tests through Automated Iterative Feedback Loops. *2025 IEEE International Conference on Software Maintenance and Evolution (ICSME)*, 930–934. https://doi.org/10.1109/ICSME64153.2025.00109

Sabir, B., Liu, S., Jang, S. I., Abuadbba, S., Gao, Y., Moore, K., Kim, S., Kim, H., & Nepal, S. (2026). *Does Teaming-Up LLMs Improve Secure Code Generation? A Comprehensive Evaluation with Multi-LLMSecCodeEval*. https://arxiv.org/abs/2603.22717

Seo, M., Choi, W., Shin, S., & You, M. (2025). *AutoPatch: Multi-Agent Framework for Patching Real-World CVEs Generated by Outdated LLMs*. https://arxiv.org/abs/2505.04195

Shahid, M. U., Ahmed, C. M., & Ranjan, R. (2025). *LLM-CSEC: Empirical Evaluation of Security in C/C++ Code Generated by Large Language Models*. https://arxiv.org/abs/2511.18966v1

Siddiq, M. L., & Santos, J. C. S. (2022). SecurityEval Dataset: Mining Vulnerability Examples to Evaluate Machine Learning-Based Code Generation Techniques. *Proceedings of the 1st International Workshop on Mining Software Repositories Applications for Privacy and Security*, 29–33. https://doi.org/10.1145/3549035.3561184

Sriram, V., Pandita, S., Lakshmanan, A., Shamraj, A., & Saha, S. (2026). *Improving LLM-Assisted Secure Code Generation through Retrieval-Augmented-Generation and Multi-Tool Feedback*. https://arxiv.org/abs/2601.00509v1

Tang, X., Kim, K., Song, Y., Lothritz, C., Li, B., Ezzini, S., Tian, H., Klein, J., & Bissyandé, T. F. (2024). CodeAgent: Autonomous Communicative Agents for Code Review. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 11279–11313. https://doi.org/10.18653/v1/2024.emnlp-main.632

Thornton, S. (2026). *Can Adversarial Code Comments Fool AI Security Reviewers – Large-Scale Empirical Study of Comment-Based Attacks and Defenses Against LLM Code Analysis*. https://arxiv.org/abs/2602.16741

Tony, C., Mutas, M., Ferreyra, N. E. D., & Scandariato, R. (2023). *LLMSecEval: A Dataset of Natural Language Prompts for Security Evaluations*. https://arxiv.org/abs/2303.09384v1

Tsigkourakos, G., & Patsakis, C. (2026). *QRS: A Rule-Synthesizing Neuro-Symbolic Triad for Autonomous Vulnerability Discovery*. https://arxiv.org/abs/2602.09774v1

Wang, J., Cao, L., Luo, X., Cao, Y., Li, Z., Xiao, Y., Zhao, M., Jatowt, A., & Cai, Y. (2026a). *Toward Secure Code Generation: Bridging Correctness and Security via Task-Adaptive Vulnerability Modeling and Execution-Based Benchmarking*. https://arxiv.org/abs/2407.02395v3

Wang, J., Luo, X., Cao, L., He, H., Huang, H., Xie, J., Jatowt, A., & Cai, Y. (2024). *Is Your AI-Generated Code Really Safe? Evaluating Large Language Models on Secure Code Generation with CodeSecEval*. https://arxiv.org/abs/2407.02395v2

Wang, P., Li, X., Xiang, C., Zhang, J., Li, Y., Zhang, L., Wang, X., & Tian, Y. (2026b). *The Landscape of Prompt Injection Threats in LLM Agents: From Taxonomy to Analysis*. https://arxiv.org/abs/2602.10453

Wang, Z. G. (2026). *Strategic Heterogeneous Multi-Agent Architecture for Cost-Effective Code Vulnerability Detection*. https://arxiv.org/abs/2604.21282

Widyasari, R., Weyssow, M., Irsan, I. C., Ang, H. W., Liauw, F., Ouh, E. L., Shar, L. K., Kang, H. J., & Lo, D. (2025). *Let the Trial Begin: A Mock-Court Approach to Vulnerability Detection using LLM-Based Agents*. https://arxiv.org/abs/2505.10961v2

Wynn, A., Satija, H., & Hadfield, G. (2025). *Talk Isn't Always Cheap: Understanding Failure Modes in Multi-Agent Debate*. https://arxiv.org/abs/2509.05396

Yang, Y., Yao, H., Yang, B., He, Y., Li, Y., Zhang, T., Qin, Z., & Ren, K. (2024). *TAPI: Towards Target-Specific and Adversarial Prompt Injection against Code LLMs*. https://arxiv.org/abs/2407.09164v3

LAMPIRAN A

PERNYATAAN PENGGUNAAN KECERDASAN BUATAN (AI)

Dengan ini, saya:

Nama Mahasiswa	:	Muhammad Adha Ridwan
NIM	:	13523098
Program Studi	:	Sarjana Teknik Informatika
Fakultas / Sekolah	:	Sekolah Teknik Elektro dan Informatika
Judul Tugas Akhir	:	Perancangan dan Implementasi Multi-Agent Security Gate dengan Evidence-Based Arbiter untuk Verifikasi Keamanan Kode Hasil Large Language Model

Menyatakan bahwa dalam pengerjaan dan penulisan Tugas Akhir ini, saya **menggunakan / tidak menggunakan** bantuan perangkat kecerdasan buatan (AI). Rincian penggunaan AI yang dilakukan adalah sebagai berikut:

Tabel 2: Rincian Penggunaan Alat AI dalam Penyusunan Tugas Akhir

Lingkup Pekerjaan	Digunakan?	Rincian dan Alat yang Digunakan
Pemeriksaan Tata Bahasa & Ejaan	Ya/Tidak	Perbaikan ejaan teks dokumen (misal: Grammarly, DeepL)
Bantuan Diskusi Konseptual	Ya/Tidak	Diskusi awal pemahaman algoritma (misal: LLM)
Pembuatan Grafis atau Diagram	Ya/Tidak	Pembuatan diagram alur data atau skema arsitektur
Penulisan Kode Sumber Program	Ya/Tidak	Pencarian referensi pustaka dan debugging fungsi spesifik

Saya menyatakan bertanggung jawab penuh atas seluruh kebenaran fakta, analisis, kode program, dan kesimpulan yang disajikan dalam Laporan Tugas Akhir ini.

Bandung, <Tanggal Pengesahan>

Muhammad Adha Ridwan
NIM : 13523098

LAMPIRAN B
CONTOH LAMPIRAN TEKNIS

B.1 Spesifikasi Lingkungan Pengujian

Uraikan informasi tambahan yang terlalu panjang atau detail jika diletakkan pada bagian utama naskah, seperti spesifikasi perangkat keras, konfigurasi server, atau cuplikan kode skrip evaluasi.